

RAG技术详解

一、什么是RAG

RAG (Retrieval Augmented Generation) 是一种将外部知识库与大语言模型结合的技术框架。在生成答案之前，先从知识库中检索与问题相关的文本片段，再将这些片段作为上下文传给模型，让模型有据可查地回答问题。RAG有效解决了模型知识过期、幻觉和私有数据三大问题。

二、RAG的核心步骤

- 第一步：数据准备。将原始文档加载进来，按照一定策略切分成小的文本块 (chunk)。
- 第二步：建立索引。对每个文本块调用Embedding模型进行向量化，将文字转换为向量，存入向量数据库。
- 第三步：检索。用户提问时，将问题向量化，在向量数据库中做相似度搜索，找出最接近的k个文本块。
- 第四步：生成答案。将检索到的文本块拼接成上下文，连同用户问题传入LLM，引导模型基于上下文生成答案。

三、常见向量数据库对比

Faiss：Facebook出品，纯本地库，速度极快，适合中小公司单机部署。Milvus：分布式架构，支持百亿级数据，适合大厂高并发场景。Chroma：轻量级，开发调试友好，适合原型开发和学习。

四、检索优化技术

混合检索：同时使用向量检索和BM25关键词检索，两者结果融合排序，兼顾语义理解和精确匹配。查询改写：用LLM将用户问题改写成更适合检索的形式，提高召回率。重排序：向量检索召回粗排后再精排，提升最终质量。HyDE：先生成假设性答案再检索，效果优于直接用问题检索。